

上海交通大學

SHANGHAI JIAO TONG UNIVERSITY

硕士研究生学位论文中期检查报告

Mid-term Examination Report for SJTU Master Student

学号 Student ID	124036910020
姓名 Name	仲垦
学生类别 Degree Program	学术型硕士生 Academic Master
学习形式 Study Mode	全日制 Full-time
导师 Supervisor(s)	王铮
专业 Major	网络空间安全
学院 School	计算机学院
考核日期 Date	

填报说明 Instruction

1. 硕士研究生学位论文中期检查应通过数字交大在线提交申请，填写本表并上传系统。特殊情况下经研究生院事先同意，可不上传系统，并使用《上海交通大学硕士论文中期检查评审表》完成评审。

   The application for thesis mid-term examination should be submitted online through My SJTU. The student shall filled this form and upload it in the system. Under special circumstance, this form does not need to be uploaded and the review can be proceeded with the review form with prior consent from the graduate school.

2. 本报告请用 A4 纸双面打印，于左侧订在一起。各栏空格不够时，请自行加页。考核前提前一周送交导师、评审专家审阅。

   This report should be printed with A4 papers and bound together on the left. If the space left is not enough, please feel free to add extra pages. The print version shall be sent to the supervisor, and the review committee members for review at least one week before the oral presentation.

3. 中期检查报告通过后，定稿版报告由研究生、导师各存档一份，无需上传系统。

   Upon passing the review, the final version of this report shall be archived by the graduate student and his/her supervisors for future reference.

中期检查报告 Mid-term Examination Report

论文题目 Thesis Title	
研究课题来源 Source of Research Project	请在合适选项前画√ Please select the proper options by "√". ☐ 国家自然科学基金课题 NSFC Research Grants ☐ 国家社会科学基金 National Social Science Fund of China ☐ 国家重大科研专项 National Key Research Projects ☐ 其它纵向科研课题 Other Governmental Research Grants ☐ 企业横向课题 R&D Projects from Industry ☐ 自拟课题 Self-proposed Project
论文开题日期 Thesis Proposal Date	

1、**报告正文 Report。**请阐述开题报告以来学位论文研究工作的进展情况及所取得的阶段性成果，并简述下一阶段研究计划，不少于 4000 汉字。Please summarize your research progress and achievements since your thesis proposal as well as your plan for next step. No less than 3200 words if written in English.

一、研究目标与总体进展

本学位论文面向关系表格学习中的模型表达与大规模训练问题，开展两项相互关联、分别验证的研究工作。关系数据库中的预测对象往往分布于多张通过主外键连接的表中，节点字段同时包含数值、类别、文本及时间等异构信息。将关系数据库转化为异构图后，模型需要识别不同连接路径承载的任务语义；随着数据库规模增长，训练过程还需要完成大规模邻域采样、原始行读取、特征编码和模型计算。前者决定跨表信息能否形成有效表示，后者决定模型能否在较大数据规模下保持可接受的内存开销和训练效率。

围绕上述问题，论文的第一项工作为基于元路径的关系表格学习方法 MetaRTL，重点研究在有限可训练消息传递深度下获取并融合跨表路径信息的方法。第二项工作为面向大规模关系表格数据的可扩展训练框架 RelX，重点研究数据规模增长条件下训练数据的按需准备、跨批复用与分阶段执行。内存占用是大规模数据训练所引发的重要约束之一，但本项研究同时关注端到端训练耗时、数据准备吞吐和计算设备等待时间。两项工作在研究对象上具有一致性，在方法与实验评价上各自形成独立的研究内容。

开题以来，已完成关系表格学习、异构图语义建模及大规模图训练相关工作的梳理，明确了两项工作的研究边界和论文结构。MetaRTL 已形成完整的方法设计与基准实验结果，相关材料已整理为学位论文的方法与实验章节。RelX 已完成训练框架的主要实现，并开展运行验证、数据路径剖析及局部优化实验。学位论文目前已形成绪论、相关基础和 MetaRTL 章节的初稿；RelX 设计与实验章节正在依据最终实现和统一实验口径继续补充。

二、基于元路径的关系表格学习方法 MetaRTL

在关系数据库构成的异构图中，同一目标实体可以通过不同主外键序列连接到其他表。不同路径对应不同语义，对具体预测任务的贡献也存在差异。直接增加图神经网络层数会扩大采样邻域，并增加重复的参数化消息传递；若在聚合过程中直接混合各类邻居信息，路径间的语义区别可能被弱化。针对这一问题，MetaRTL 将初始节点表示学习与高阶关系聚合分为两个阶段，分别处理异构字段编码和多跳关系语义融合。

第一阶段采用按表类型配置的表格编码器，将各表中的原始字段转化为共同维度的节点表示，再结合两层异构图神经网络，以训练任务的监督信号更新编码器参数。该阶段采用有限训练轮次，目的在于获得包含字段信息及局部关系信息的初始节点表示，为后续元路径传播提供输入。实验配置中，表格编码器采用四层、隐藏维度为 128 的 ResNet 风格结构，异构图网络采用两层、隐藏维度为 128 的 GraphSAGE 风格结构，预训练阶段进行五个训练轮次。

第二阶段首先按照关系模式构造候选元路径。对一条从源表类型到目标表类型的元路径，将沿途各关系的度归一化邻接矩阵相乘，形成相应的路径传播矩阵；再将第一阶段得到的节点表示沿该路径传播，形成目标节点的路径特征。候选元路径最长为四跳。传播过程不包含需要反向传播更新的变换参数，并可复用较短路径的中间计算结果。对于同一目标节点，不同路径生成的特征分别保留，以便后续模块学习路径间的相对重要性。元路径矩阵的构造与存储开销受关系模式和矩阵非零元数量影响，因而需要结合具体数据库结构分析其规模适用范围。

为融合路径语义与跨批共享信息，MetaRTL 设计了 MetaAttn 模块。其元路径自注意力分支在路径维度上建立依赖关系，区分不同跨表连接模式对预测任务的贡献；全局节点交叉注意力分支使用共享的节点原型作为键和值，使目标节点在当前采样批次之外获得补充的统计信息。实验设置中使用 4096 个共享原型。两条分支的输出经拼接与线性映射形成最终目标节点表示，再由任务预测头完成分类或回归。该结构将多跳关系传播与可训练语义融合分开，减少训练过程中反复执行深层可训练邻域聚合的需求。

方法评价覆盖 SJTUTables 与 RelBench 两组公开关系表格数据，共十个数据库、二十四项预测任务。SJTUTables 的三个多分类任务采用准确率评价，MetaRTL 在 TACM12k、TLF2K 和 TML1M 上分别取得 46.54%、43.17% 和 37.09% 的准确率，均为相应对照表中的最高值。RelBench 的十二个二分类任务和九个回归任务分别采用 ROC-AUC 与平均绝对误差评价。在二十一项任务中，MetaRTL 有十七项单独取得最优结果，一项与对照方法并列最优，其余三项未达到最优。上述结果表明，该方法在不同数据库与任务上具有较强的预测性能，同时也反映出各任务从高阶路径信息中获得的收益并不完全相同。

在模块作用分析方面，已在 rel-f1 数据集的三个任务上开展消融实验。移除元路径特征后，driver-top3 的 ROC-AUC 从 0.8415 降至 0.6294，driver-position 的平均绝对误差从 3.987 升至 4.870；移除表格编码器预训练或全局节点交叉注意力，也会使这三个任务的结果下降。这些实验为初始表示学习、路径传播和注意力聚合的作用提供了实证依据。预训练轮次实验表明，五轮训练能够以较少轮次获得可用的初始表示，但不同任务的最佳轮次并不完全一致。固定平均出度的合成图实验显示，在该设置下训练时间随节点数增加大致呈线性增长；对于其他关系模式，仍需结合路径矩阵的实际稀疏度考察预计算开销。

目前，MetaRTL 的研究问题、方法公式、基准结果及消融分析已整理为学位论文的独立章节。后续将进一步核对训练损失、优化参数、时间约束处理以及实验重复次数等实现记录，并据此完善论文中的可复现性描述和结果分析。

三、大规模关系表格数据可扩展训练框架 RelX

第二项工作针对关系表格训练过程中的规模扩展问题。小批次图模型训练虽然只在每次迭代处理部分目标节点，但训练前若完整加载原始表或物化所有编码特征，内存需求仍会随着数据库规模增加。改为按批读取后，数据库访问、异构字段转换和文本编码又可能延迟批次生成，使模型计算等待数据。与一般图训练相比，关系表格训练还需要将采样得到的节点标识映射回数据库原始行，并根据字段类型生成模型输入。因此，可扩展训练需要同时处理常驻数据规模、逐批准备成本与各执行阶段之间的资源匹配。

RelX 将训练过程划分为采样、特征准备与批次组装、模型训练三个阶段。采样进程根据训练种子和邻域采样规则生成批次计划；组装进程池依据计划读取各表中实际需要的行，执行数值、类别、时间及文本字段的转换，并恢复采样批次要求的节点顺序；训练进程消费已完成的批次，执行设备传输及模型更新。阶段间通过有界队列连接，使不同批次的采样、组装与训练能够重叠。队列与在途窗口设置资源预算，以约束预取批次和中间数据的占用。训练阶段保留轮次边界及任务标签的原有语义，数据准备则可在不改变训练样本归属的前提下提前执行。

为降低重复读取与重复编码，框架在批次计划层面对节点请求去重，并在特征准备阶段引入分层复用。对重复出现的节点，可复用已编码的表格特征；对重复文本，可复用对应的向量表示。跨进程共享缓存用于避免不同组装进程独立保存同一批特征，并通过预留与发布状态协调并发缺失请求。针对文本量较大、跨轮次重复访问较多的负载，框架还支持持久化文本向量；缓存键纳入数据库版本、编码模型及特征模式等信息，以维持复用结果与训练输入的一致性。这些机制以减少重复工作和控制内存增长为目的，是否产生端到端收益需结合具体数据集与训练时长评价。

目前已完成 RelX 主要模块的实现，包括独立的采样进程、可配置的组装进程池、训练进程、有界计划队列与就绪队列，以及跨批次复用机制。框架可记录批次准备、训练与队列等待等阶段耗时，并支持对不同缓存与执行设置进行比较。已有十项真实任务完成双轮训练运行，累计处理 76186 个批次，验证了三阶段执行流程在多种关系数据库任务上的可运行性。对小规模任务的验证也显示，增加组装进程可能引入额外调度成本，因此并行度需要结合负载特征设置，不能仅依据进程数量判断训练效率。

为确定数据准备的主要开销，已对十个本地关系数据库进行字段转换剖析。所检查的 71 张含特征表涉及 518 个特征列，包括数值、类别、时间和文本等类型。在固定的单线程样本处理条件下，文本相关处理占各列可归因处理时间的 85.3%，说明长文本编码及其复用是值得重点研究的环节。该比例来自局部字段转换测试，不代表完整训练过程的时间占比；实际端到端表现还受采样、数据库读取、缓存命中、并行组装和设备计算影响。

在数据库读取方面，已开展跨批次请求合并与读取策略的受控实验。针对十个数据库中的十八张代表性特征表，使用相同节点请求比较逐批精确读取与窗口合并读取，并核验返回行的内容及顺序。在独立确认使用的请求样本上，按数据集选定的窗口配置使局部读取时间相对逐批精确读取缩短，十个数据库的比值范围为 2.19 至 3.41。该实验隔离了读取阶段，尚未计入模型训练和组装进程间的队列行为，因而不能直接解释为端到端训练加速。实验同时发现，在请求密度不足时扩大连续读取范围会引入额外行解码，提示读取策略需要结合请求分布与表宽选择。

上述实现与实验已使 RelX 的研究重点由单一的内存节省扩展为面向大规模数据的整体训练可扩展性。现阶段已形成关于执行阶段划分、数据复用和局部瓶颈的证据；不同数据库规模下的端到端训练表现、整作业内存峰值及完整组件消融仍需在统一条件下进一步测量。RelX 的实验对象为既定关系表格训练任务，MetaRTL 与 RelX 的联合部署尚未纳入当前结果。

四、阶段性成果与尚待解决的问题

截至中期检查，已取得的阶段性成果主要包括：其一，完成 MetaRTL 两阶段模型设计、二十四项公开任务的性能评价及主要模块消融，并形成相应小论文材料和学位论文方法章节；其二，实现 RelX 的三阶段训练框架、按需特征准备与多层复用机制，完成十项任务的双轮运行验证；其三，针对字段转换和数据库读取开展可复核的局部实验，为后续端到端评价提供瓶颈定位与参数选择依据；其四，确定以模型语义表达和可扩展训练为两条主线的学位论文整体结构。

当前仍有三方面问题需要解决。首先，MetaRTL 的部分实现与实验记录需要进一步归档，尤其是各任务损失函数、优化设置、时间约束处理和重复试验条件，以保证学位论文方法描述与实验条件完整一致。其次，RelX 的局部优化结果需要在统一基线、相同硬件和相同训练任务下验证其端到端收益，避免将读取或编码阶段的改善直接推及整体训练。最后，规模扩展实验需要同时呈现训练吞吐、初始化耗时、整作业内存与存储开销，分析不同数据规模及字段结构下的适用范围。

五、下一阶段研究计划

下一阶段首先完成 MetaRTL 实验资料核对和论文修订。将依据训练配置与代码记录补全分类、回归任务的目标函数，核实优化器、学习率、批大小、邻居采样、模型选择和随机种子等参数；对于具有预测时刻的任务，核查元路径关系和源节点特征的时间可见性。随后统一图表、术语和参考文献，并检查方法公式、实验表格及文字结论之间的一致性。

RelX 方面，将建立统一的端到端对照实验。比较方法需要使用相同的数据库版本、任务划分、采样设置、模型结构、训练步数和硬件环境。评价指标除预测质量外，还包括完整运行时间、冷启动准备时间、每秒完成批次数、模型等待输入的时间、整作业内存峰值及必要的磁盘占用。针对每项任务，记录缓存冷暖状态和重复运行情况，以便解释不同数据集上的性能差异。进一步通过关闭或替换跨批请求去重、共享缓存、文本复用及流水线并行等组件，分析各设计对端到端结果的实际贡献。

在规模扩展评价中，将在可比的训练配置下改变数据规模或选择规模差异明显的数据库，观察端到端耗时、吞吐和内存随规模增长的变化，并区分数据行数、关系稀疏度和字段类型造成的影响。对于文本字段占比较高、访问重复率较低或高并发读取的负载，重点检查组装阶段是否仍为瓶颈，以及缓存带来的内存与存储代价。根据实验结果完善自适应的工作进程数、读取窗口与缓存预算设置，明确 RelX 的有效应用条件和当前实现边界。

最后，将完成 RelX 设计与实验章节、全文总结及中英文摘要，统一两项工作的术语、符号与评价口径。论文将分别呈现 MetaRTL 的模型预测结果和 RelX 的训练系统结果；若后续完成两者的实际集成与同条件评估，再单独报告联合实验。通过上述工作，形成研究问题明确、实验依据充分、结论与证据范围相一致的硕士学位论文。

2、**成果清单 List of Achievements。**请列出开题报告以来或上次年度进展报告以来新发表的学术论文、授权专利、国际会议论文、专著等成果清单。作者、标题、杂志、卷、期、页码等信息请填写完整。 Please provide a list of academic publications (papers, patents, international academic conference talks/presentations, monographs, etc.) since your thesis proposal. Information on author list, title, journal name, volume, number, and pages shall be complete.

本人承诺：报告中的内容真实无误，若有不实，愿承担相应的责任和后果。 I hereby declare and confirm that the details provided in this Form are valid and accurate. If anything untruthful found, I will bear the corresponding liabilities and consequences.

学生签字/Signature of Student： **日期/Date：** 2026-11-03